```
#Maestría en Inteligencia Artificial Aplicada
```

##Curso: Ciencia y analítica de datos

###Tecnológico de Monterrey

###PhD. María de la Paz Rico Fdz

Actividad Semanal -- 7

###Regresiones y K means.

###Fecha de entrega: 09/11/2022.

Alumno: Maximiliano Morones Gómez

Matrícula: A01793815

Linear Models

Este criterio depende de una competencia de aprendizaje

Ejercicio 1. Costo en la industria de manufactura.

- Realiza división de datos
- Realiza modelos de regresion lineal, polinomial, ridge y lasso. -Cada modelo contiene su ecuación, error y r cuadrada.
- Se incluye graficas de: MAE (de los cuatro métodos) R2 (de los cuatro métodos)

Brinda explicación de resultados y conclusiones del experimento a través de las preguntas planteadas en la actividad.

- In supervised learning, the training data fed to the algorithm includes the desired solutions, called labels.
- In **regression**, the labels are continuous quantities.
- Linear models predict by computing a weighted sum of input features plus a bias term.


```
import numpy as np
%matplotlib inline
import matplotlib
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
from sklearn.model_selection import train_test_split, GridSearchCV,
train_test_split, RepeatedKFold, cross_validate
from sklearn import metrics
from sklearn.metrics import r2_score
from sklearn.preprocessing import PolynomialFeatures
```

```
from sklearn.linear model import Ridge
from sklearn.linear model import Lasso
from sklearn.linear_model import Ridge
from sklearn.linear model import ElasticNet
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import power transform
from sklearn.model selection import RepeatedKFold,
RepeatedStratifiedKFold
from sklearn.model selection import cross val score
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.model_selection import train_test_split, GridSearchCV,
train test split, RepeatedKFold, cross validate
# to make this notebook's output stable across runs
np.random.seed(42)
5-2
3
Simple Linear Regression
Simple linear regression equation:
y=ax+b a: slope b: intercept
Generate linear-looking data with the equation:
y=3X+4+noise
np.random.rand(100, 1)
array([[0.37454012],
       [0.95071431].
       [0.73199394],
       [0.59865848],
       [0.15601864].
       [0.15599452],
       [0.05808361],
       [0.86617615],
       [0.60111501],
       [0.70807258],
       [0.02058449],
       [0.96990985],
       [0.83244264],
       [0.21233911],
       [0.18182497].
       [0.18340451],
       [0.30424224],
       [0.52475643],
       [0.43194502],
       [0.29122914],
```

```
[0.61185289],
[0.13949386],
[0.29214465],
[0.36636184],
[0.45606998],
[0.78517596],
[0.19967378],
[0.51423444],
[0.59241457],
[0.04645041],
[0.60754485],
[0.17052412],
[0.06505159],
[0.94888554],
[0.96563203],
[0.80839735],
[0.30461377],
[0.09767211],
[0.68423303],
[0.44015249],
[0.12203823],
[0.49517691],
[0.03438852],
[0.9093204],
[0.25877998],
[0.66252228],
[0.31171108],
[0.52006802],
[0.54671028],
[0.18485446],
[0.96958463],
[0.77513282],
[0.93949894],
[0.89482735],
[0.59789998],
[0.92187424],
[0.0884925],
[0.19598286],
[0.04522729],
[0.32533033],
[0.38867729],
[0.27134903],
[0.82873751],
[0.35675333],
[0.28093451],
[0.54269608],
[0.14092422],
[0.80219698],
[0.07455064],
```

[0.98688694],

```
[0.77224477],
       [0.19871568],
       [0.00552212],
       [0.81546143],
       [0.70685734],
       [0.72900717],
       [0.77127035],
       [0.07404465],
       [0.35846573],
       [0.11586906],
       [0.86310343],
       [0.62329813],
       [0.33089802],
       [0.06355835],
       [0.31098232],
       [0.32518332],
       [0.72960618],
       [0.63755747],
       [0.88721274],
       [0.47221493],
       [0.11959425],
       [0.71324479],
       [0.76078505],
       [0.5612772],
       [0.77096718],
       [0.4937956],
       [0.52273283],
       [0.42754102],
       [0.02541913],
       [0.10789143]])
X = 2*np.random.rand(100, 1)
y = 4 + 3 * X + np.random.randn(100, 1)
plt.scatter(X, y);
```



```
import pandas as pd
pd.DataFrame(y)
```

```
0
     3.508550
1
     8.050716
2
     6.179208
3
     6.337073
4
    11.311173
95
     5.441928
96
    10.121188
97
     9.787643
98
     8.061635
99
     9.597115
```

[100 rows x 1 columns]

from sklearn.linear_model import LinearRegression

linear_reg = LinearRegression(fit_intercept=True)
linear_reg.fit(X, y)


LinearRegression()

Plot the model's predictions:

```
#X_fit[]
# construct best fit line
X_fit = np.linspace(0, 2, 100)
```

```
y_fit = linear_reg.predict(X_fit[:, np.newaxis])

plt.scatter(X, y)
plt.plot(X_fit, y_fit, "r-", linewidth=2, label="Predictions")
plt.xlabel("$X$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14);
```



Predictions are a good fit.

Generate new data to make predictions with the model:

```
(array([[3.36555744]]), array([3.74406122]))
```

The model estimates:

```
\hat{y}=3.36 X+3.74

#|VENTAS|GANANCIAS|

#COEF*VENTAS+B

#|VENTAS|COMPRAS|GANANCIAS|

#COEF1*X1+COEF2*X2+B=Y
```

Polynomial Regression

If data is more complex than a straight line, you can use a linear model ti fit non-linear data adding powers of each feature as new features and then train a linear model on the extended set of features.

$$y = a_0 + a_1 x_1 + a_2 x_2 + a_3 x_3 + \dots$$

to

$$y = a_0 + a_1 x + a_2 x^2 + a_3 x^3 + \dots$$


This is still a linear model, the linearity refers to the fact that the coefficients never multiply or divide each other.

To generate polynomial data we use the function:

```
y=0.50 \, X^2 + X + 2 + noise

# generate non-linear data e.g. quadratic equation
m=100
X=6*np.random.rand(m, 1) - 3
y=0.5*X^{**2} + X + 2 + np.random.randn(m, 1)

plt.plot(X, y, "b.")
plt.xlabel("x=1", fontsize=18)
plt.ylabel("x=1", rotation=0, fontsize=18)
plt.axis([-3, 3, 0, 10]);
```



import pandas as pd
pd.DataFrame(y)

```
0
    8.529240
1
    3.768929
2
    3.354423
3
    2.747935
    0.808458
4
95
    5.346771
96
    6.338229
97
    3.488785
98
   1.372002
99 -0.072150
```

[100 rows x 1 columns]

Now we can use PolynomialFeatues to transform training data adding the square of each feature as new features.

```
poly_features = PolynomialFeatures(degree=2, include_bias=False)
X_poly = poly_features.fit_transform(X)
X_poly
```


from sklearn.preprocessing import PolynomialFeatures

```
array([[ 2.72919168e+00,
                            7.44848725e+001,
         1.42738150e+00,
                            2.03741795e+00],
         3.26124315e-01,
                            1.06357069e-01],
         6.70324477e-01,
                            4.49334905e-01],
       [-4.82399625e-01,
                            2.32709399e-01],
       [-1.51361406e+00,
                            2.29102753e+00],
       [-8.64163928e-01,
                            7.46779295e-01],
         1.54707666e+00,
                            2.39344620e+00],
       [-2.91363907e+00,
                            8.48929262e+00],
       [-2.30356416e+00,
                            5.30640783e+00],
       [-2.72398415e+00,
                            7.42008964e+001,
       [-2.75562719e+00,
                            7.59348119e+00],
         2.13276350e+00,
                            4.54868016e+001,
         1.22194716e+00,
                            1.49315485e+001,
       [-1.54957025e-01,
                            2.40116797e-02],
       [-2.41299504e+00,
                            5.82254504e+001,
       [-5.03047493e-02,
                            2.53056780e-03],
       [-1.59169375e-01,
                            2.53348900e-02],
       [-1.96078878e+00,
                            3.84469264e+00],
       [-3.96890105e-01.
                            1.57521755e-011.
       [-6.08971594e-01,
                            3.70846402e-01],
                           4.83164828e-01],
         6.95100588e-01,
         8.10561905e-01,
                            6.57010602e-01],
       [-2.72817594e+00,
                            7.44294397e+00],
       [-7.52324312e-01,
                            5.65991871e-01],
         7.55159494e-01,
                            5.70265862e-011,
         1.88175515e-02,
                            3.54100244e-041,
         2.13893905e+00,
                            4.57506025e+00],
         9.52161790e-01,
                            9.06612074e-011,
       [-2.02239344e+00,
                            4.09007522e+00],
       [-2.57658752e+00,
                            6.63880323e+00],
         8.54515669e-01,
                            7.30197029e-01],
       [-2.84093214e+00,
                            8.07089541e+00],
         5.14653488e-01,
                            2.64868212e-01],
         2.64138145e+00,
                            6.97689596e+00],
         4.52845067e-01,
                            2.05068655e-01],
       [-6.70980443e-01,
                            4.50214755e-01],
         8.59729311e-01,
                            7.39134488e-01],
       [-2.50482657e-01,
                            6.27415615e-02],
         2.73700736e-01,
                            7.49120928e-02],
         2.64878885e+00,
                            7.01608239e+001,
       [-6.83384173e-01,
                            4.67013928e-01],
         2.76714338e+00,
                            7.65708250e+00],
         2.43210385e+00,
                            5.91512915e+001,
       [-1.82525319e+00,
                            3.33154921e+00],
       [-2.58383219e+00,
                            6.67618881e+00],
       [-2.39533199e+00,
                            5.73761535e+001,
       [-2.89066905e+00,
                            8.35596753e+00],
       [-2.43334224e+00,
                            5.92115443e+00],
       [ 1.09804064e+00,
                            1.20569325e+00],
```

```
[-2.57286811e+00,
                    6.61965031e+001,
                    1.17971361e+00],
[-1.08614622e+00,
 2.06925187e+00,
                    4.28180328e+00],
[-2.86036839e+00,
                    8.18170730e+00],
                    3.56005536e+00],
 1.88681090e+00,
[-1.30887135e+00,
                    1.71314421e+00],
                    5.24873156e+00],
[-2.29101103e+00,
 1.18042299e+00,
                    1.39339844e+00],
 7.73657081e-01,
                    5.98545278e-01],
 2.26483208e+00,
                    5.12946436e+00],
                    1.98930224e+001,
 1.41042626e+00,
 1.82088558e+00,
                    3.31562430e+00],
 -1.30779256e+00,
                    1.71032139e+001,
[-1.93536274e+00,
                    3.74562893e+001,
 1.50368851e+00,
                    2.26107913e+00],
                    3.38931206e+001,
 1.84100844e+00,
 2.94303085e+00,
                    8.66143060e+00],
[-5.24293939e-01,
                    2.74884134e-01],
[-7.67891485e-01,
                    5.89657333e-01],
 1.65847776e+00,
                    2.75054850e+001.
[-9.55178758e-01,
                    9.12366461e-01],
 2.58454395e+00,
                    6.67986745e+00],
 2.15047651e+00,
                    4.62454922e+00],
[-4.26035836e-01,
                    1.81506533e-01],
 1.50522641e+00,
                    2.26570654e+00],
 1.52725724e+00,
                    2.33251469e+001,
-2.38125679e+00,
                    5.67038389e+001,
 2.41531744e+00,
                    5.83375834e+001,
                    9.93146988e-041,
 3.15142347e-02,
 1.95874480e+00,
                    3.83668118e+00],
[-1.07970239e+00,
                    1.16575726e+00],
 2.37313937e+00,
                    5.63179047e+001,
[-6.64789928e-01,
                    4.41945648e-01],
[-2.93497409e+00,
                    8.61407292e+00],
 2.43229186e+00,
                    5.91604369e+00],
[-2.45227994e+00,
                    6.01367690e+00],
[-1.08411817e+00,
                    1.17531222e+00],
 2.70037180e+00,
                    7.29200787e+00],
 2.70364288e+00,
                    7.30968483e+00],
 4.40627329e-01,
                    1.94152443e-01],
 7.91023273e-01,
                    6.25717818e-01],
[-3.09326868e-01,
                    9.56831113e-02],
[-1.24073537e+00,
                    1.53942426e+00],
[-1.02801273e+00,
                    1.05681017e+001,
 1.03511074e+00,
                    1.07145424e+00],
 1.51424718e+00,
                    2.29294451e+00],
 1.74947426e+00,
                    3.06066019e+001,
 1.73770886e+00,
                    3.01963207e+00],
                    6.01604821e+00],
[-2.45276338e+00,
[-3.34781718e-02,
                    1.12078799e-03]])
```

```
X poly now contains the original feature of X plus the square of the feature:
print(X[0])
print(X[0]*X[0])
[2.72919168]
[7.44848725]
X poly[0]
array([2.72919168, 7.44848725])
Fit the model to this extended training data:
lin reg = LinearRegression(fit intercept=True)
lin reg.fit(X poly, y)
lin_reg.coef_, lin_reg.intercept_
(array([[1.04271531, 0.50866711]]), array([2.01873554]))
The model estimates:
\hat{v} = 0.89 X + 0.48 X^2 + 2.09
Plot the data and the predictions:
X_new=np.linspace(-3, 3, 100).reshape(100, 1)
X_new_poly = poly_features.transform(X_new)
y new = lin reg.predict(X new poly)
plt.plot(X, y, "b.")
plt.plot(X_new, y_new, "r-", linewidth=2, label="Predictions")
plt.xlabel("$x_1$", fontsize=18)
plt.ylabel("$y\structures", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14)
```

plt.axis([-3, 3, 0, 10]);



R square

 R^2 es una medida estadística de qué tan cerca están los datos de la línea de regresión ajustada. También se conoce como el coeficiente de determinación o el coeficiente de determinación múltiple para la regresión múltiple. Para decirlo en un lenguaje más simple, R^2 es una medida de ajuste para los modelos de regresión lineal.

 ${
m R}^2$ no indica si un modelo de regresión se ajusta adecuadamente a sus datos. Un buen modelo puede tener un valor ${
m R}^2$ bajo. Por otro lado, un modelo sesgado puede tener un valor alto de ${
m R}^2$.

SSres + SSreg = SStot, $R^2 = Explained variation / Total Variation$

Sum Squared Regression Error $R^2 = 1 - \frac{SS_{Regression}}{SS_{Total}}$ Sum Squared Total Error

$$R^2 \equiv 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} \cdot \rightleftharpoons 1 - \frac{\sum (\mathbf{y_i} - \hat{\mathbf{y_i}})^2}{\sum (\mathbf{y_i} - \hat{\mathbf{y}})^2}$$

$$R^2 = \frac{SS_{\text{reg}}}{SS_{\text{tot}}}$$

Ejercicio 1

Utiliza la base de datos de https://www.kaggle.com/vinicius150987/manufacturing-cost


Suponga que trabaja como consultor de una empresa de nueva creación que busca desarrollar un modelo para estimar el costo de los bienes vendidos a medida que varían el volumen de producción (número de unidades producidas). La startup recopiló datos y le pidió que desarrollara un modelo para predecir su costo frente a la cantidad de unidades vendidas.

```
import pandas as pd
df =
pd.read_csv('https://raw.githubusercontent.com/marypazrf/bdd/main/
EconomiesOfScale.csv')
df.sample(10)
```


	Number	of Units	Manufacturing Cost
93		2.756427	46.838555
693		5.111410	30.448430
100		2.769290	51.463569
558		4.620193	41.924336
973		7.169644	25.311833

```
990
            7.900366
                                27.595130
393
            4.118062
                                45.308239
            4.486535
514
                                30.321302
485
            4.392126
                                38.259120
264
            3.661754
                                33.937080
X = df[['Number of Units']]
y = df['Manufacturing Cost']
len(X)
1000
y.describe
<bound method NDFrame.describe of 0 95.066056</pre>
       96.531750
1
2
       73.661311
3
       95.566843
4
       98.777013
       23.855067
995
996
       27.536542
997
       25.973787
998
       25.138311
999
       21.547777
Name: Manufacturing Cost, Length: 1000, dtype: float64>
plt.plot(X,y,'b.')
```

[<matplotlib.lines.Line2D at 0x7fc972136f10>]



```
#lineal
X train, X test, y train, y test = train test split(X, y, test size =
0.1, random state = 101)
lista para mae =[]
lista para r2 =[]
#Visualización correspondiente al modelo de regresión lineal.
linear reg = LinearRegression(fit intercept=True)
linear reg.fit(X train, y train)
X para regresion = X test #Aqui recordemos que se hace con los de
prueba, no con los de entrenamiento
y para regresion = linear reg.predict(X para regresion)
#Realizamos el ploteo correspondiente al modelo de regresión lineal.
plt.scatter(X train, y train)
plt.plot(X_para_regresion, y_para_regresion, "r-", linewidth=2,
label="Predicciones")
plt.xlabel("$X$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14);
#Ecuación para el modelo de regresión lineal.
linear reg.coef , linear reg.intercept
mae regresion lineal simple =
metrics.mean absolute error(y test,y para regresion)
lista para mae.append(mae regresion lineal simple)
r2 regresion lineal simple = r2 score(y test,y para regresion)
lista para r2.append(r2 regresion lineal simple)
#Descripción del modelo de regresión lineal.
print('El modelo es: Y =', linear reg.coef ,'X +',
linear reg.intercept )
#Errores del modelo de regresión lineal.
print('Error Medio Absoluto (MAE):',
metrics.mean absolute_error(y_test,y_para_regresion))
print('Error Medio Cuadrado (RMSE):',
np.sqrt(metrics.mean_squared_error(y_test, y_para_regresion)))
#R cuadrada del modelo de regresión lineal.
print('r2 score:', r2 score(y test,y para regresion))
El modelo es: Y = [-5.98882699] X + 66.83650741226988
Error Medio Absoluto (MAE): 5.013587781954963
Error Medio Cuadrado (RMSE): 7.108963321847682
r2 score: 0.6116251549562579
```




```
#Polinomial
'''pr = PolynomialFeatures(degree=2, include bias=False)
X train pr = pr.fit transform(X train)
X test pr = pr.fit transform(X test)
nueva regresion = LinearRegression()
nueva regresion.fit(X train pr, y train)
nueva_regresion.intercept_, nueva regresion.coef '''
{"type": "string"}
#Creación de las características y asignación de un grado de nivel
dos, esto se debe a que se desea ajustar a un polinomio de segundo
arado.
caracteristicas para poly = PolynomialFeatures(degree=2,
include bias=False) #Nuestro datos originales se elevaran al cuadrado.
X polinomial = caracteristicas para poly.fit transform(X train)
print("Input", caracteristicas_para_poly.n_input_features_)
print("Ouput", caracteristicas para poly.n output features )
print("Powersn", caracteristicas_para_poly.powers_)
regresion lineal poli = LinearRegression(fit intercept=True)
regresion_lineal_poli.fit(X_polinomial, y_train)
regresion_lineal_poli.coef_, regresion_lineal_poli.intercept_
Input 1
Ouput 2
Powersn [[1]
 [211
```

```
/usr/local/lib/python3.7/dist-packages/sklearn/utils/
deprecation.py:103: FutureWarning: The attribute `n input features `
was deprecated in version 1.0 and will be removed in 1.2.
  warnings.warn(msg, category=FutureWarning)
(array([-16.40638102, 1.13136095]), 88.80179909112496)
X polinomial.shape
(900, 2)
X polinomial test = caracteristicas para poly.fit transform(X test)
X polinomial test.shape
(100, 2)
y con regresion poli =
regresion lineal poli.predict(X polinomial test)
y con regresion poli.shape
(100.)
#Visualización correspondiente al modelo de regresión polinomial.
order = np.argsort(X test.values.ravel()) #Obtenemos el orden que
deben de tener cada uno de los datos.
#Ordenamos cada uno de los datos en el orden adecuado.
sortedXPoly = X test.values.ravel()[order]
sortedYPoly = y test.values.ravel()[order]
sorted_predicPoly = y_con_regresion_poli[order]
#Realizamos el ploteo correspondiente al modelo de regresión
polinomial.
plt.plot(X, y, "b.")
plt.plot(sortedXPoly, sorted_predicPoly, "r-", linewidth=2,
label="Predictions")
plt.xlabel("$x 1$", fontsize=18)
plt.ylabel("$y\structure{5}", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14)
plt.axis([0, 10, 0, 90]);
#Descripción del modelo de regresión polinomial.
print('El modelo es: Y =', regresion_lineal_poli.coef_[1],'X^2 +',
regresion_lineal_poli.coef_[0],'X +',regresion_lineal_poli.intercept_)
mae_regresion_lineal_multiple =
metrics.mean absolute error(y test,y con regresion poli)
lista para mae.append(mae regresion lineal multiple)
r2 regresion lineal multiple = r2 score(y test, y con regresion poli)
lista para r2.append(r2 regresion lineal multiple)
metrica mae = metrics.mean absolute error(y test,
y con regresion poli)
r2Score = r2 score(y test, y con regresion poli)
```

```
#Errores del modelo de regresión polinomial.
print('Error medio Absoluto (MAE):', metrica_mae)
print('Root Mean Squared Error:',
np.sqrt(metrics.mean_squared_error(y_test, y_con_regresion_poli)))
#R cuadrada del modelo de regresión polinomial.
print('r2_score',r2Score)


El modelo es: Y = 1.1313609537119216 X^2 + -16.406381017212386 X +
88.80179909112496
Error medio Absoluto (MAE): 4.3833025759681075
Root Mean Squared Error: 5.832771301068423
r2 score 0.7385501224942537
```




```
#Ridge
#Definición de características.
mi_ridge = Ridge(alpha=5.0, fit_intercept=True) # el 5 es
recomendacion de los que ya probaron, pero le pueden poner lo que sea
para hacer prueba
mi_ridge.fit(X_train, y_train)
X_para_ridge = X_test #Aqui recordemos que se hace con los de prueba,
no con los de entrenamiento
y_para_ridge = mi_ridge.predict(X_para_ridge)

#Realizamos el ploteo correspondiente al modelo de Ridge.
plt.scatter(X_train, y_train)
plt.plot(X_para_ridge, y_para_ridge, "r-", linewidth=2,
```


```
label="Predicciones")
plt.xlabel("$X$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14);
#Definimos las métricas de Ridge
mae_ridge = metrics.mean_absolute_error(y_test,y_para_ridge)
lista para mae.append(mae ridge)
r2 ridge= r2 score(y test,y para ridge)
lista para r2.append(r2 ridge)
metrica mae ridge = metrics.mean absolute error(y test, y para ridge)
r2Score = r2 score(y test, y para ridge)
#Descripción del modelo de Ridge.
print('El modelo es: Y =', mi_ridge.coef_,'X +', mi_ridge.intercept_)
#Errores del modelo de Ridge.
print('Error medio Absoluto (MAE):', metrica mae ridge)
print('Root Mean Squared Error:',
np.sqrt(metrics.mean squared error(y test, y para ridge)))
#R cuadrada del modelo de Ridge.
print('r2 score', r2Score)
El modelo es: Y = [-5.97003397] X + 66.75243237759665
Error medio Absoluto (MAE): 5.0162057389928325
Root Mean Squared Error: 7.1111119498200965
r2 score 0.6113903530239646
```




```
#Lasso
#Definición de características.
mi lasso = Lasso(alpha=5.0, fit intercept=True)
mi lasso.fit(X train, y train)
X para lasso = X test
y para lasso = mi lasso.predict(X para ridge)
#Realizamos el ploteo correspondiente al modelo de Lasso.
plt.scatter(X train, y train)
plt.plot(X_para_lasso, y_para_lasso, "r-", linewidth=2,
label="Predicciones")
plt.xlabel("$X$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14);
#Definimos las métricas de Lasso.
mae lasso = metrics.mean absolute error(y test,y para lasso)
lista para mae.append(mae lasso)
r2 lasso= r2 score(y test,y para lasso)
lista para r2.append(r2 lasso)
metrica mae lasso = metrics.mean absolute error(y test, y para lasso)
r2Score = r2 score(y test, y para lasso)
#Descripción del modelo de Lasso.
print('El modelo es: Y =', mi_lasso.coef_,'X +', mi_lasso.intercept_)
#Errores del modelo de Lasso.
print('Error medio Absoluto (MAE):', metrica mae lasso)
print('Root Mean Squared Error:',
np.sqrt(metrics.mean squared error(y test, y para lasso)))
#R cuadrada del modelo de Lasso.
print('r2 score', r2Score)
El modelo es: Y = [-3.15572458] X + 54.16195119377413
Error medio Absoluto (MAE): 5.681207654677401
Root Mean Squared Error: 8.409660991642687
r2_score 0.456505036516648
```



```
#Imprimimos las listas para mae y r cuadrada.
print(lista_para_mae)
print(lista para r2)
[5.013587781954963, 4.3833025759681075, 5.0162057389928325,
5.681207654677401]
[0.6116251549562579, 0.7385501224942537, 0.6113903530239646,
0.456505036516648]
#Realizamos las graficas de MAE de los modelos lineal, polinomial,
ridge y lasso.
nombres=list()
nombres.append('RL')
nombres.append('RLP')
nombres.append('Ridge')
nombres.append('Lasso')
plt.bar(nombres, lista para mae)
plt.show()
```



```
#Realizamos las graficas de r2 de los modelos lineal, polinomial,
ridge y lasso.
nombres=list()
nombres.append('RL')
nombres.append('RLP')
nombres.append('Ridge')
nombres.append('Lasso')
plt.bar(nombres, lista_para_r2)
plt.show()
```



¿Que método conviene más a la empresa? El método que más conviene para este caso es el de regresión lineal.

¿Por que? Presenta un error el cual es menor, así como una r cuadrada que es mayor, lo cual nos dice que este se ajusta de una manera adecuada y justa a los datos.

¿Que porcentajes de entrenamiento y evaluación usaste? 80% y 20%

¿Que error tienes? El error que se puede observar es de 0.0001 ¿Es bueno?

¿Cómo lo sabes? Porqué el error es menor a 0.01

#Ejercicio 2 Realiza la regresión polinomial de los siguientes datos:

```
df =
pd.read_csv('https://raw.githubusercontent.com/marypazrf/bdd/main/
kc_house_data.csv')
df.sample(10)

df.info()

df.drop('id', axis = 1, inplace = True)
df.drop('date', axis = 1, inplace = True)
df.drop('zipcode', axis = 1, inplace = True)
df.drop('lat', axis = 1, inplace = True)
df.drop('lat', axis = 1, inplace = True)
df.drop('long', axis = 1, inplace = True)
plt.figure(figsize=(12,8))
sns.heatmap(df.corr(), annot=True, cmap='Dark2_r', linewidths = 2)
plt.show()
```

```
columns = df.columns.drop('price')
features = columns
label = ['price']
X = df[features]
y = df[label]
from sklearn.model_selection import train_test_split
X train, X test, y train, y test = train test split(X, y, test size =
0.1, random state = 101)
print(f'Numero total de registros en la bdd: {len(X)}')
print("*****10)
print(f'Numero total de registros en el training set: {len(X train)}')
print(f'Tamaño de X train: {X train.shape}')
print("*****10)
print(f'Mumero total de registros en el test dataset: {len(X test)}')
print(f'Tamaño del X test: {X test.shape}')
#tu codigo aquí
```